Лекция 4. Функции потерь и метрики качества

Приближение набора точек прямой

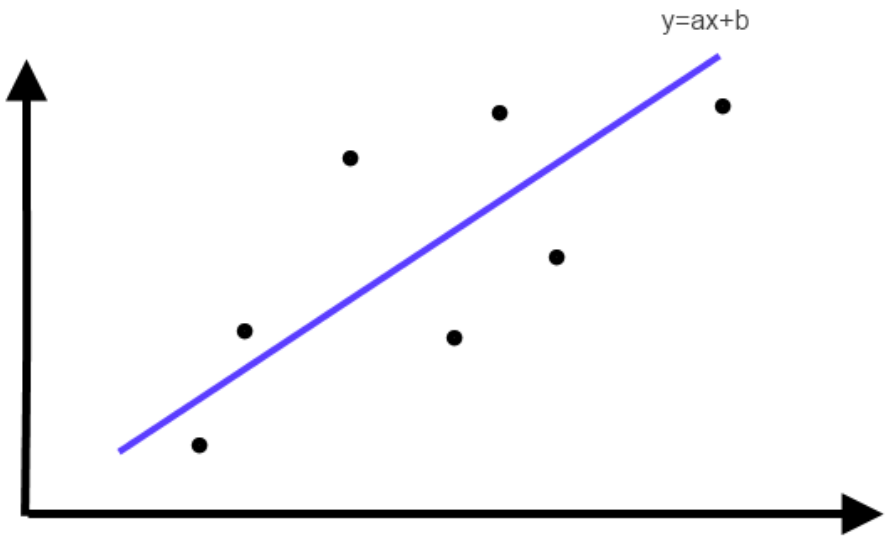

1. Как понять, что прямая «хорошо» аппроксимирует точки?
2. Как это учесть в алгоритме обучения?

Функция потерь

Функция потерь

Функция потерь (loss function) $L(y, \hat{y})$ — это математическая функция, которая количественно оценивает разницу между предсказаниями модели $\hat{y}$ и истинными значениями целевой переменной y.
Пусть задан параметризованный алгоритм $\hat{y} = f(x, w)$.
Математическое ожидание функции потерь относительно истинного распределения данных $D(x, y)$:

$$R(f) = \mathbb{E}_{(x,y)\sim P}\left[L(y, f(x, w))\right]$$

Минимизация эмпирического риска

$$R(f) = \frac{1}{n}\sum_{i=1}^{n}\left[L(y_i, f(x_i, w))\right]$$

Пример. Оценка параметра

- Метод максимального правдоподобия
- Оценка апостериорного максимума
- Байесовская оценка

Ещё пример

Вахтер хочет понять кого пускать в парадную. Он хочет минимизировать свою работу (больше спать) по:

- проверке входящих;
- разборкам с жильцами/руководством;
- уборке/проветриванию.

Для этого ему надо проверять входящих (думать).Однако, минимизировать «время сна» напрямую очень сложно. Задача помочь бедному вахтеру.

Из слайдов курса CSC

Желаемые свойства

Влияние функции потерь на ландшафт и методы решения задачи оптимизации

- Выпуклость: легко оптимизировать.
- Дифференцируемость: производная по параметрам модели существует и непрерывна. Позволяет использовать градиентные методы оптимизации.
- Гладкость: должна иметь непрерывный градиент и не иметь резких переходов или скачков.

Свойства решения

- Робастность: должна уметь работать с выбросами и не зависеть от небольшого числа экстремальных значений.
- Разреженность: должна стимулировать модель к получению разреженных результатов (уменьшение числа признаков).
- Монотонность: значение уменьшается по мере приближения прогнозируемого выхода к истинному.

Чему следовать, выбирая функцию потерь

- Чувство прекрасного;
- Возможность применять математику:
  - Скорость вычисления;
  - Дифференцируемость;
- Наличие интересных внутренних параметров;
- Возможность проверить осмысленность промежуточных результатов. Чем больше мы в области, тем больше знания мы можем перенести в целевую функцию.

Проблемы при построении

Что может быть «не так» в очевидном решении:

- функция может быть неудобна для оптимизации;
- сложно гарантировать несмещённость по параметрам оптимизации;
- сложно собирать данные в терминах функции потерь

Функции потерь в задачах глубокого обучения

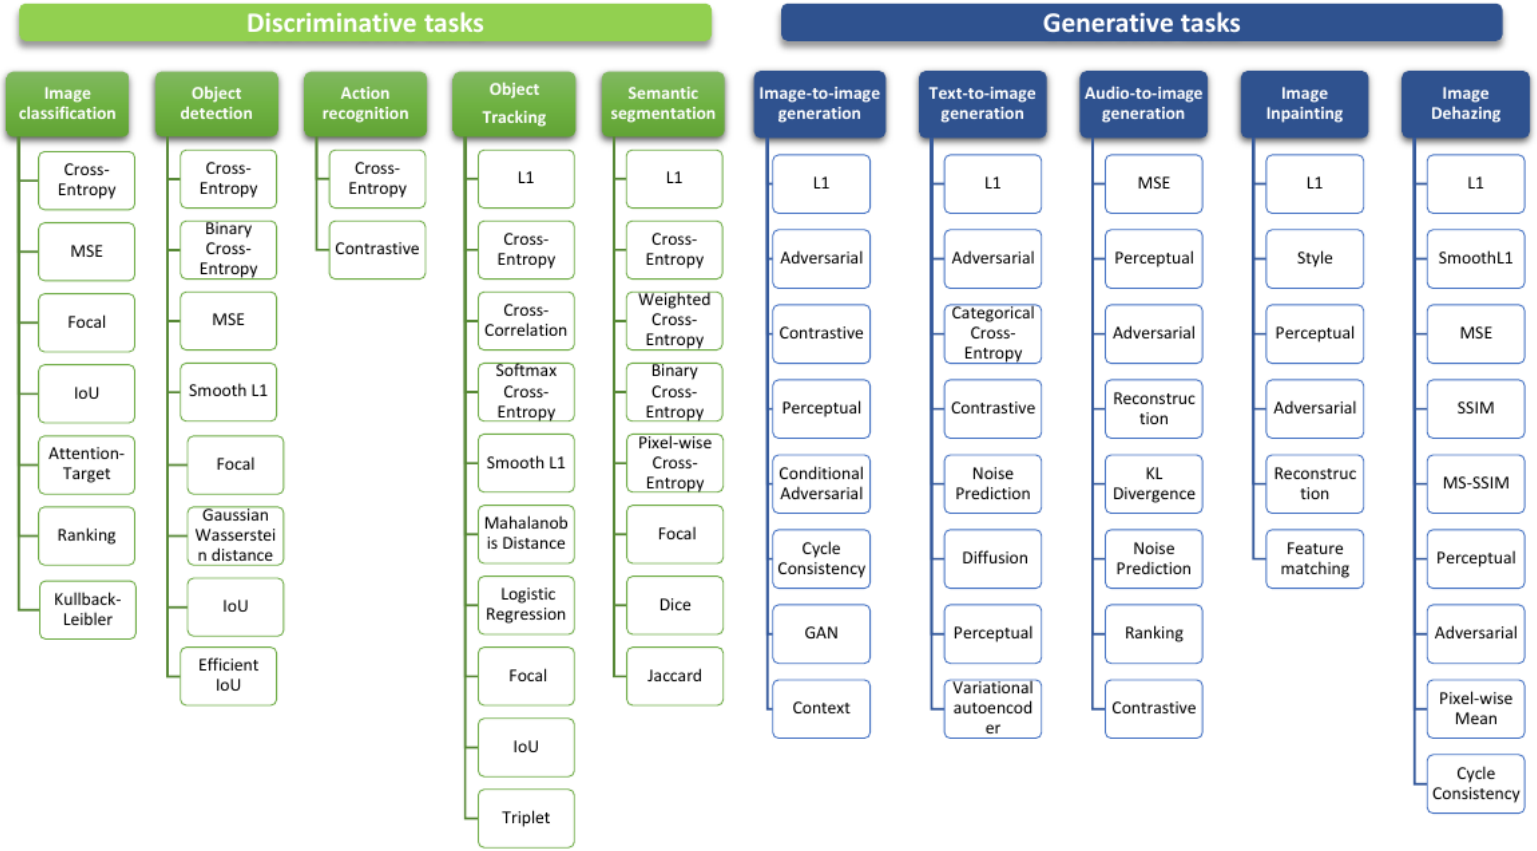

Из «Loss Functions in Deep Learning: A Comprehensive Review», 2025

Эволюция функций потерь

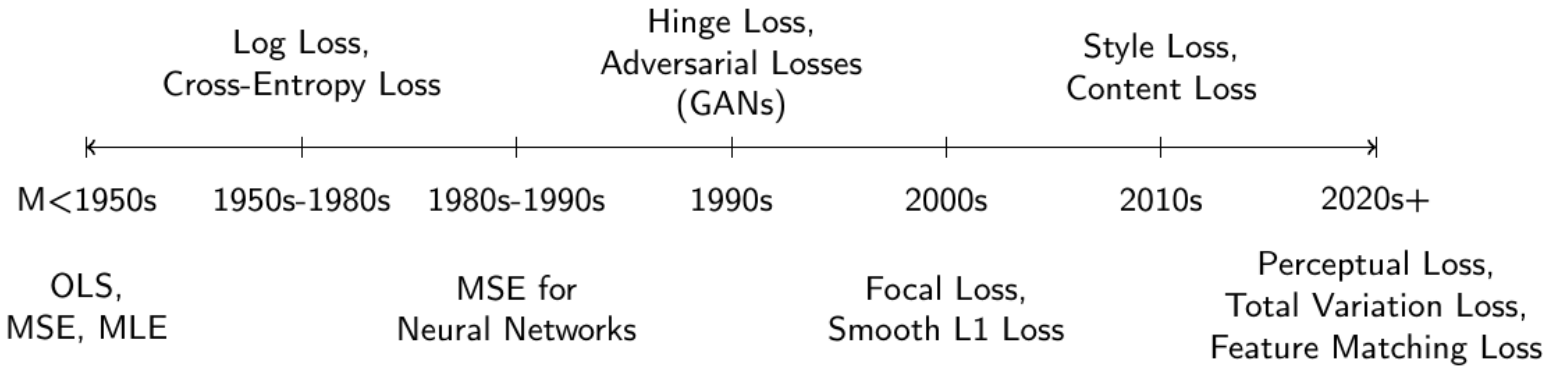

Figure 3: Timeline of the evolution of loss functions.

Из «Loss Functions in Deep Learning: A Comprehensive Review», 2025

Регрессия

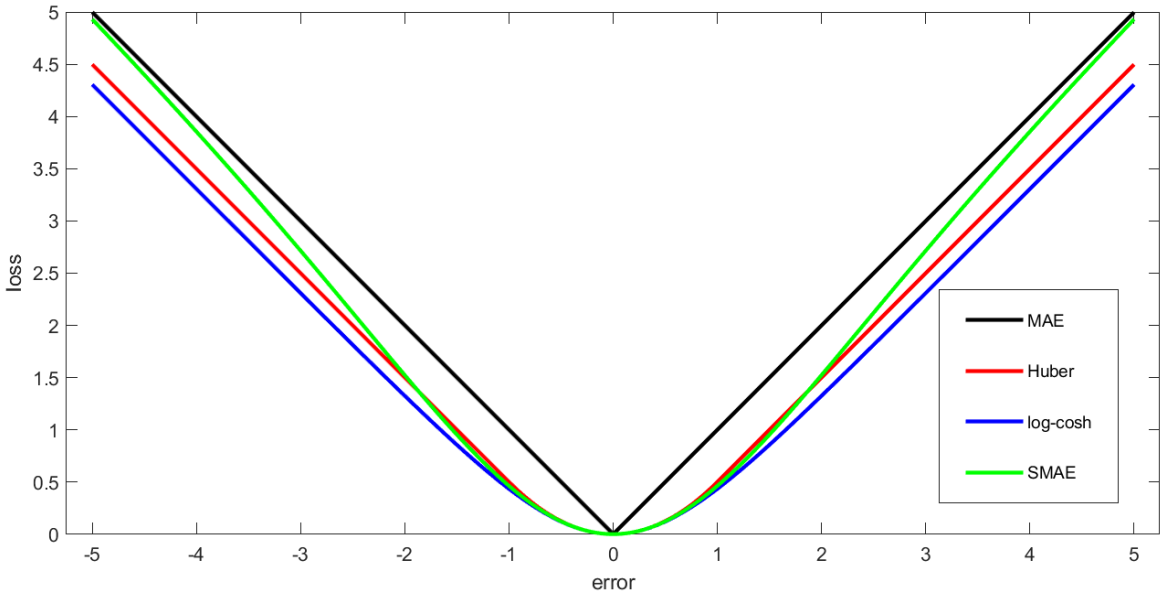
loss
error
MAE
Huber
log-cosh
SMAE
5
4.5
4
3.5
3
2.5
2
1.5
1
0.5
0
-5
-4
-3
-2
-1
0
1
2
3
4
5

Регрессия

- MSE (Mean Squared Error)

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

  - дифференцируемая
  - выпуклая
  - чувствительна к выбросам
  - зависит от масштаба

- MAE (Mean Average Error)

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

  - недифференцируемая
  - выпуклая
  - менее чувствительная к выбросам
  - зависит от масштаба

Регрессия

- Huber loss

$$L_\delta(y, \hat{y}) = \begin{cases} \frac{1}{2}(y - \hat{y})^2, & \text{если } |y - \hat{y}| \leq \delta \\ \delta|y - \hat{y}| - \frac{1}{2}\delta^2, & \text{иначе} \end{cases}$$

Бинарная классификация

- BCE (Binary Cross Entropy, Log loss)

$$\text{BCE} = -\frac{1}{n}\sum_{i=1}^{n}\left[y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i)\right]$$

  - Дифференцируемая
  - Вероятностная интерпретация
  - Штраф зависит от уверенности предсказания
  - Чувствительна к несбалансированности классов
- Hinge loss

$$\text{Hinge} = \frac{1}{n}\sum_{i=1}^{n}\max(0, 1 - y_i \cdot s_i)$$

  - Выход +1 или -1
  - Штрафует, даже если ответ верный, но слишком близко к границе

Многоклассовая классификация

- Cross Entropy loss

$$\mathrm{CE} = -\frac{1}{n}\sum_{i=1}^{n}\sum_{c=1}^{C} y_{i,c}\log(\hat{y}_{i,c})$$

- Focal loss

$$\mathrm{FL} = -\frac{1}{n}\sum_{i=1}^{n}(1-p_t)^{\gamma}\log(p_t)$$

Классификация

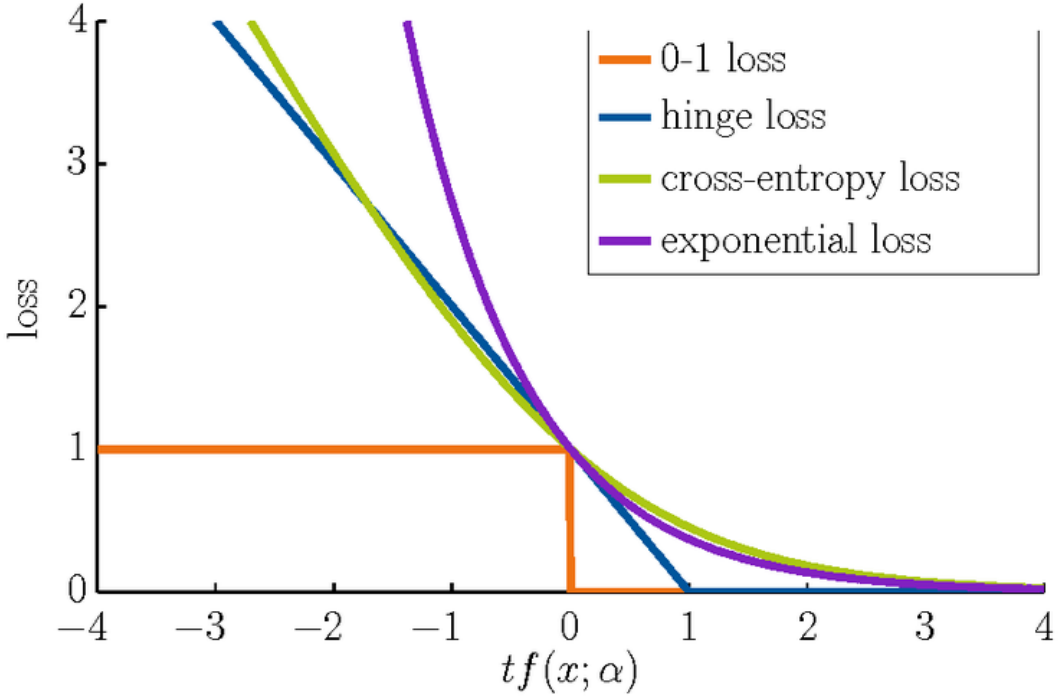

Регуляризация

$$\hat{y} = f(x, w)$$

$$L(w) + R(w) \to \min$$

Метрики качества

Задача регрессии

- MSE

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

- RMSE

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

Задача регрессии

- MAE (Mean Absolute Error)

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

- MBE (Mean Bias Error) — мера смещения

$$\mathrm{MBE} = \frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)$$

Задача регрессии

- MAPE (Mean Absolute Percentage Error)

$$\text{MAPE} = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right| \times 100\%$$

  - Плохо для близких к нулю значений
  - Больше штрафует за отрицательные ошибки
  - При недопрогнозировании ошибка не более 100 %, при перепрогнозировании не ограничена

- SMAPE (Symmetric Mean Absolute Percentage Error)

$$\text{SMAPE} = \frac{1}{n}\sum_{i=1}^{n}\frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2} \times 100\%$$

  - Плохо для близких к нулю значений
  - По-разному штрафует за перепрогнозирование и недопрогнозирование

Задача регрессии

Коэффициент детерминации R^2 — доля дисперсии зависимой переменной, объясняемая рассматриваемой моделью зависимости.

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

- Хорош для линейных моделей
- Может быть отрицательным (модель хуже среднего целевой переменной)
- Чувствителен к выбросам
- Значение увеличивается (не уменьшается) от добавления в модель новых переменных, даже если эти переменные никакого отношения к объясняемой переменной не имеют.

Бинарная классификация

- Confusion matrix
- Accuracy
- Precision
- Recall
- F-measure
- ROC-AUC

Confusion matrix

Confusion Matrix

	Actually Positive (1)	Actually Negative (0)
Predicted Positive (1)	True Positives (TPs)	False Positives (FPs)
Predicted Negative (0)	False Negatives (FNs)	True Negatives (TNs)

Бинарная классификация

- Accuracy — отношение числа правильно классифицированных примеров к общему числу

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN}$$

- Precision

$$Precision = \frac{TP}{TP + FP}$$

- Recall

$$Recall = \frac{TP}{TP + FN}$$

Бинарная классификация

F-measure (F-score, F1) – среднее геометрическое между precision и recall. Ближе к меньшему из precision, recall

$$F1 = 2\frac{Precision \times Recall}{Precision + Recall}$$

Бинарная классификация

- ROC-AUC применяется для оценки «вероятностной» классификации. Оценивает качество ранжирования объектов по вероятности принадлежности к целевому классу
- AUC – площадь под кривой
- Sensitivity (true positive rate) – отражает долю положительных результатов, которые правильно идентифицированы как таковые.

$$TPR = \frac{TP}{TP + FN}$$

- Specificity (true negative rate) отражает долю отрицательных результатов, которые правильно идентифицированы как таковые.

$$FPR = \frac{FP}{FP + TN}$$

ROC

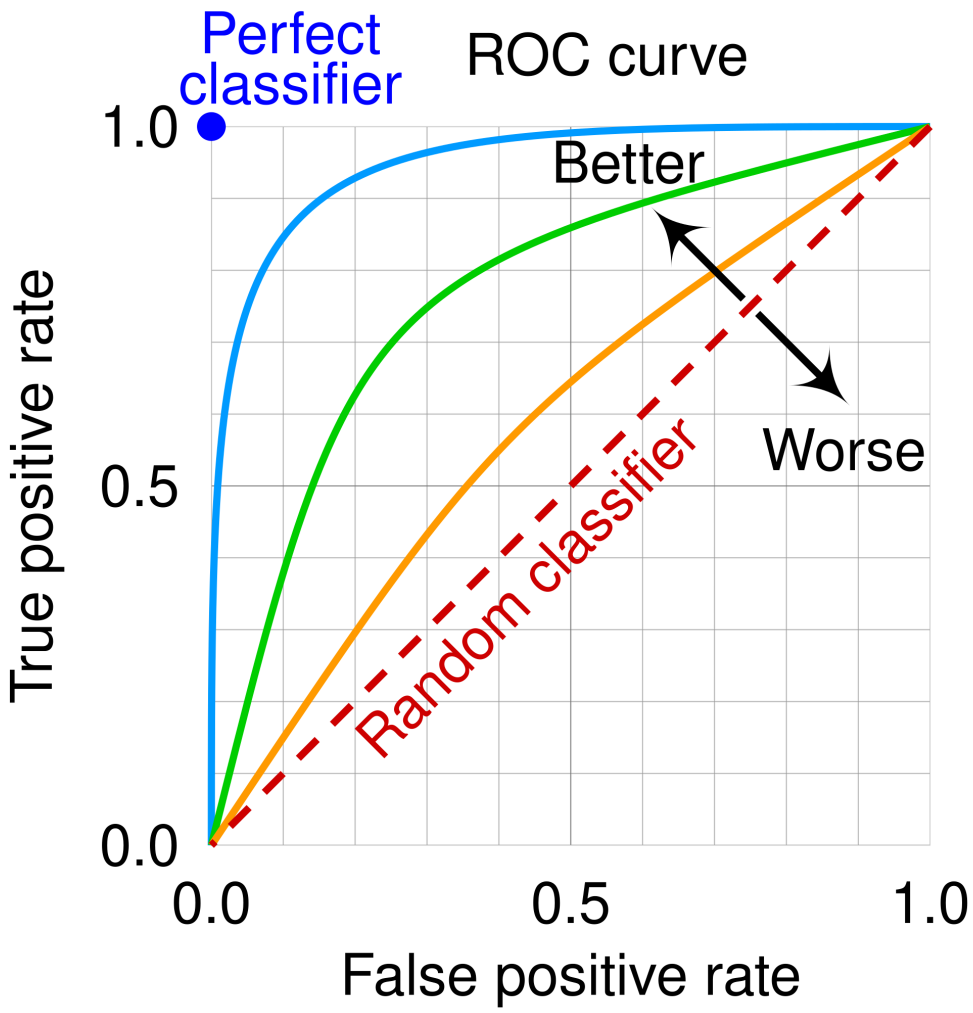
Perfect classifier
ROC curve
1.0
Better
Worse
0.5
Random classifier
0.0
True positive rate
0.0
0.5
1.0
False positive rate

Precision-Recall curve

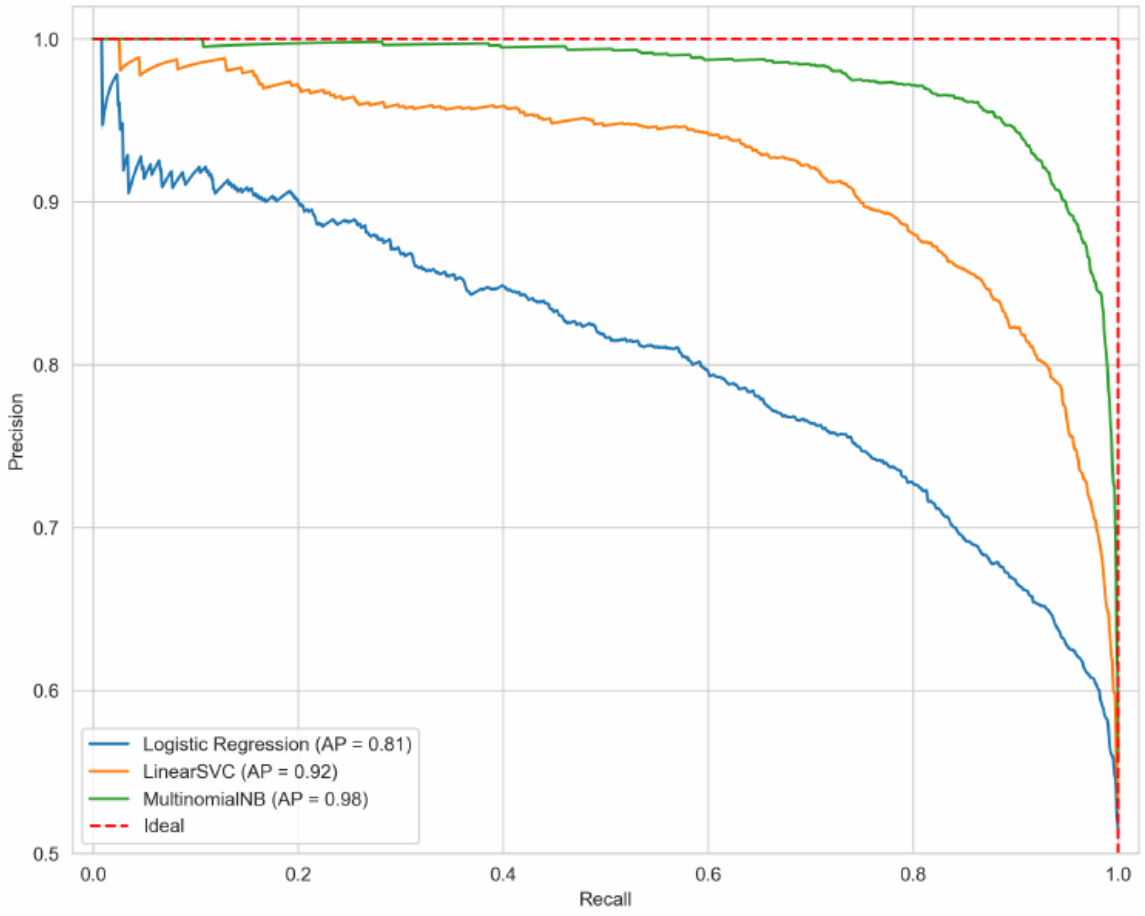

Многоклассовая классификация

- Сведение к двухклассовому случаю
- Обобщение алгоритмов на многоклассовый случай

Сведение к двухклассовому случаю

One-vs-One

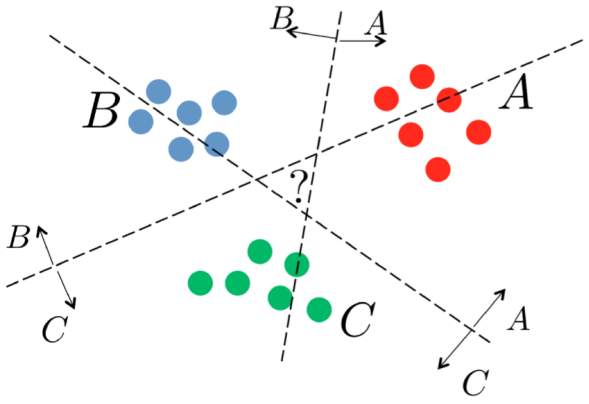

$\frac{K(K-1)}{2}$ бинарных классификаторов

One-vs-Rest

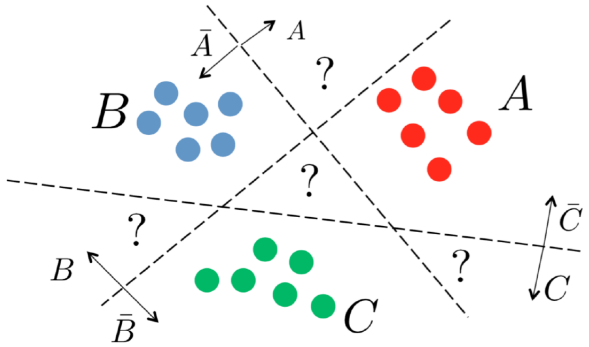

K бинарных классификаторов

Многоклассовая классификация

- Confusion matrix
- Accuracy
- Recall и precision
  - Macro-average: независимо для каждого класса и усредняем (одинаковый вес всех классов)
  - Micro-average: считаем сумму TP, FP, FN по всем классам (общая эффективность на всех объектах)
- Recall@k, Precision@k

Оценка качества системы

Какие метрики использовать? На каких данных измерять? Метрики всей системы или отдельных частей?

Обзоры

- Loss functions and metrics in deep learning, 2025
- Loss Functions in Deep Learning: A Comprehensive Review, 2025
- etc

Задача

Какие бы вы взяли метрики качества для следующих задач?

1. Multilabel classification
2. Sound events detection