

Кластеризация и понижение размерности

Что такое кластеризация

Задача разбиения заданной выборки объектов на подмножества, называемые кластерами, так, чтобы каждый кластер состоял из схожих объектов, а объекты разных кластеров существенно отличались.

Математическая постановка

Исходные данные:

- X — множество объектов,
- Y — множество идентификаторов (меток) кластеров,
- $\rho : X \times X \rightarrow \mathbb{R}_{\geq 0}$ — функция расстояния между объектами,
- конечная обучающая выборка $X_m = \{x_1, \dots, x_m\} \subset X$.

Цель: разбить выборку X_m на подмножества (кластеры), то есть каждому объекту $x_i \in X_m$ сопоставить метку $y_i \in Y$, так чтобы:

- объекты внутри каждого кластера были **близки** относительно метрики ρ ,
- объекты из разных кластеров **значительно различались**.

Алгоритм кластеризации: функция $a : X \rightarrow Y$, которая любому объекту $x \in X$ ставит в соответствие идентификатор кластера $y \in Y$.

Теорема невозможности (Kleinberg, 2003)

1 Масштабная инвариантность (Scale-Invariance)

$a(\rho) = a(\alpha \cdot \rho)$ для любого $\alpha > 0$.

Единицы измерения не должны влиять на результат.

2 Полнота (Richness)

Для любого разбиения P множества X существует метрика ρ , такая что $a(\rho) = P$.

Алгоритм способен выдать любое теоретически возможное разбиение.


3 Согласованность (Consistency)

Если преобразовать расстояния так, что внутрикластерные уменьшатся, а межкластерные увеличатся (монотонное сохранение структуры), то a не должна измениться.

Theorem (Теорема невозможности)

Для множества объектов, состоящего из двух и более элементов, не существует алгоритма кластеризации, который был бы одновременно масштабно-инвариантным, согласованным и полным.

Картинка



Кластеризация

Кластеризация не решает задачу «найти истину», а выявляет структуры, согласованные с выбранной моделью сходства.

Типы входных данных

- Признаковое описание объектов.
- Матрица расстояний между объектами. Каждый объект описывается расстоянием до всех объектов из обучающей выборки.

Цели кластеризации

- **Классификация объектов.** Попытка понять зависимости между объектами путем выявления их кластерной структуры. Разбиение выборки на группы схожих объектов упрощает дальнейшую обработку данных и принятие решений, позволяет применить к каждому кластеру свой метод анализа. В данном случае стремятся уменьшить число кластеров для выявления наиболее общих закономерностей;
- **Сжатие данных.** Можно сократить размер исходной выборки, взяв один или несколько наиболее типичных представителей каждого кластера. Здесь важно наиболее точно очертить границы каждого кластера, их количество не является важным критерием;
- **Обнаружение новизны (обнаружение шума).** Выделение объектов, которые не подходят по критериям ни в один кластер. Обнаруженные объекты в дальнейшем обрабатывают отдельно.

Виды кластеризации

- Centroid-based (k-means)
- Connectivity-based (иерархические алгоритмы)
- Distribution-based (ЕМ-алгоритм)
- Constraint-based (semi-supervised clustering)

K-Means

- 1 Выбираем K точек и объявляем их центрами масс
- 2 Для каждой точки из выборки ищем ближайший центр масс и относим её к кластеру этого центра масс
- 3 Вычисляем новые центры масс

<https://www.naftaliharris.com/blog/visualizing-k-means-clustering/>

Преимущества:

- Простота и вычислительная эффективность.
- Хорошо работает на сферических, равномерных кластерах.
- Сходимость к локальному минимуму за конечное число шагов

Недостатки:

- Нужно заранее задавать k (число кластеров).
- Чувствителен к инициализации (k-means++ помогает).
- Предполагает выпуклые, примерно одинаковые по размеру кластеры.
- Чувствителен к выбросам.

Односвязный алгоритм (Single-linkage clustering)

- 1 Выбираем случайную точку и кладём её в кластер
- 2 Ищем соседей с расстоянием ближе, чем ρ и добавляем их в кластер
- 3 Если соседи кончились, то берём следующую точку и проделываем п. 2
- 4 Если больше не добавить точек, то переходим к п. 1

Преимущества:

- Способен выделять кластеры произвольной формы (вытянутые, «цепочки»).
- Прост в реализации.

Недостатки:

- Чувствителен к шуму и выбросам (один «мостик» может объединить два кластера).
- Склонен к «эффекту цепочки» (chain effect).

Метрики качества кластеризации

- Внешние — используют дополнительные знания о кластеризуемом множестве: распределение по кластерам, количество кластеров и т.д.
- Внутренние — оценивают качество структуры кластеров опираясь только непосредственно на нее, не используя внешней информации.

Внутренние метрики

- Среднее внутрикластерное расстояние (компактность)
- Среднее межкластерное расстояние (отделимость)
- Силуэт — насколько объект похож на свой кластер по сравнению с другими кластерами:

$$S(x_i) = \frac{B(x_i) - A(x_i)}{\max(B(x_i), A(x_i))},$$

где $A(x_i)$ — среднее расстояние между x_i и объектами того же кластера, $B(x_i)$ — среднее расстояние между x_i и объектами ближайшего другого кластера.


- Индекс Дэвиса-Болдуина

$$DB = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \frac{s_i + s_j}{d(\mathbf{c}_i, \mathbf{c}_j)},$$

где s_i — среднее расстояние от объектов кластера i до его центроида (внутренний разброс), $d(\mathbf{c}_i, \mathbf{c}_j)$ — расстояние между центроидами кластеров.

Выбор числа кластеров

- 1 Вычисляем метрику
- 2 Рисуем график
- 3 Выбираем k



DBSCAN

- 1 Выбираем случайную непосещённую точку
- 2 Если у неё больше, чем m соседей в радиусе r , то кладем её в K и создаём новый кластер, который включает все точки из окрестности, иначе помечаем как шум.
- 3 Если точка из окрестности уже является частью другого кластера C_j , то все точки данного кластера добавляются в кластер K .


<https://www.naftaliharris.com/blog/visualizing-dbscan-clustering/>

Понижение размерности

- 1 Избавляемся от шума и корреляций
- 2 Ускоряем вычисления
- 3 Визуализация

Метод главных компонент

Хотим аппроксимировать данные линейным многообразием меньшей размерности.



Метод главных компонент

Пусть $X \in \mathbb{R}^{n \times m}$, $W \in \mathbb{R}^{m \times k}$ и

$$T = XW$$

- Минимизируем ошибку проецирования
- Максимизируем дисперсию (больше дисперсия — больше информации)

t-SNE: визуализация локальной структуры

- **Идея:** минимизация KL-дивергенции между распределениями сходства в исходном и низкоразмерном пространствах.
- **Механизм:**
 - ❶ В высоком d : гауссовы распределения, параметр perplexity $\approx$ эффективное число соседей.
 - ❷ В низком d (2D/3D): t-распределение с тяжёлыми хвостами (предотвращает “слипание” кластеров).
- **Ключевые свойства:**
 - ▶ **Сохраняет локальные окрестности**, глобальные расстояния **не интерпретируемы**.
 - ▶ Стохастический: разные запуски $\rightarrow$ разные картины (фиксировать seed!).
 - ▶ Вычислительно затратен $O(n^2)$, не подходит для $n > 10^4$ без Barnes-Hut/FFT оптимизаций.

UMAP: баланс скорости и структуры

Основная идея

Построение взвешенного графа ближайших соседей в $\mathcal{X}$, оптимизация его низкоразмерного представления через стохастический градиентный спуск. Теоретическая база: алгебраическая топология и риманова геометрия.

vs. t-SNE

- Сохраняет и локальную, и **глобальную** структуру лучше
- Работает в 10–50 раз быстрее
- Меньше чувствителен к выбору гиперпараметров
- Поддерживает преобразование новых данных (transform)

Гиперпараметры

- `n_neighbors`: баланс локаль/глобаль ($\uparrow$ = больше глобальной структуры)
- `min_dist`: минимальное расстояние между точками ($\downarrow$ = плотнее кластеры)
- `metric`: euclidean, cosine, manhattan, custom